

MoE水印对抗释义攻击的核心机理优势 简化版

yunhao

1 核心问题

传统词元-逻辑值（Token-Logit）水印在面对释义攻击时存在根本性脆弱性。本文从信息论角度证明，基于MoE专家激活的水印范式具有机理上的根本优势。

2 两种范式的核心差异

2.1 范式A：稠密模型水印（KGW）

信号载体：词元概率分布（词汇表空间）

攻击向量：词元替换（词汇表空间）

核心问题：信号与攻击在同一空间，导致信号-攻击重合

衰减机理：线性衰减

$$\Delta Z \propto \gamma \quad (1)$$

其中 γ 为攻击强度（被替换词元比例）。

2.2 范式B：MoE水印

信号载体：专家激活分布 $p(e|x)$ （内部激活空间）

攻击向量：词元替换 $x \rightarrow x'$ （外部词元空间）

核心优势：信号与攻击在不同空间，实现信号-攻击解耦

衰减机理：次线性衰减

$$\Delta D^* \propto O(\sqrt{\gamma}) \quad (2)$$

3 机理推导

3.1 攻击建模

将释义攻击 $x \rightarrow x'$ 建模为输入分布偏移：

$$\gamma = D_{\text{KL}}(D(X') \| D(X)) \quad (3)$$

3.2 核心定理

定理 1 (对抗鲁棒性). 在强度为 γ 的释义攻击下, MoE 水印的检测能力 ($Chernoff$ 信息) 满足:

$$D_{adv}^* \geq D^*(p_0, p_1) - C\sqrt{\gamma \cdot D^*(p_0, p_1)} - O(\gamma) \quad (4)$$

其中 $C \approx 1.5-2.0$ 为常数。

证明思路: 通过Pinsker不等式, 输入空间的KL散度 γ 传播到激活空间时, 被约束为 $\sqrt{\gamma}$ 量级的总变差距离, 从而检测能力衰减为次线性。

3.3 为什么是 $\sqrt{\gamma}$?

关键步骤:

1. 空间解耦: 攻击 γ 在输入空间, 信号 D^* 在激活空间

2. Pinsker不等式:

$$\|p' - p\|_{TV} \leq \sqrt{\frac{1}{2} D_{KL}(p' \| p)} \quad (5)$$

3. 传播约束: 输入分布的攻击 γ 导致激活分布变化:

$$\|p'_i - p_i\|_{TV} \leq \sqrt{2\gamma} \quad (6)$$

4. 结论: 检测能力衰减 ΔD^* 被 $O(\sqrt{\gamma})$ 约束

4 对比分析

4.1 数值示例

假设初始 $D^* = 0.1$, $C = 1.5$:

• 攻击1: $\gamma_1 = 0.005$

– 衰减项: $1.5 \cdot \sqrt{0.005 \cdot 0.1} \approx 0.0335$

– 剩余 $D_{adv}^* \geq 0.0665$ (损失33.5%)

• 攻击2: $\gamma_2 = 0.020$ (4倍于攻击1)

– 衰减项: $1.5 \cdot \sqrt{0.020 \cdot 0.1} \approx 0.0671$

– 剩余 $D_{adv}^* \geq 0.0329$ (损失67.1%)

关键观察: 攻击强度增加4倍, 信号损失仅增加2倍 ($\sqrt{4} = 2$)。

4.2 线性 vs 次线性衰减

攻击强度 γ	范式A (线性)	范式B (次线性)
0.01	信号保留75%	信号保留52.6%
0.02	信号保留50%	信号保留32.9%
0.04	信号完全丢失	仍可检测 (5.1%)

核心优势: 次线性衰减在强攻击下仍保持可检测性, 而线性衰减会灾难性失效。

5 工程框架

5.1 安全系数 c

将水印强度 ϵ 与预期攻击强度 γ 关联：

$$\epsilon \approx c \cdot \sqrt{\gamma} \quad \text{或} \quad D^* \approx c^2 \gamma \quad (7)$$

鲁棒性保证： 若 $c > C$ （约1.5–2.0），则 $D_{\text{adv}}^* > 0$ ，水印理论上保证可检测。

6 核心结论

1. 信号-攻击解耦是MoE水印鲁棒性的根本原因
2. 次线性衰减（ $O(\sqrt{\gamma})$ ）vs 线性衰减（ $O(\gamma)$ ）是机理上的根本差异
3. 通过Pinsker不等式，输入空间的攻击被约束为激活空间的 $\sqrt{\gamma}$ 量级变化
4. 次线性衰减提供了可检测性下限，而线性衰减会完全失效

备注

- 实验验证：待完成
- 详细证明：待后续补充
- 本文仅展示核心理论机理